

Лабораторна 4

Датасет:

LJ Speech Dataset — один із найбільш відомих відкритих датасетів для задач синтезу мовлення. Він був зібраний та опублікований компанією Keithito і широко використовується в академічних та промислових TTS-системах як стандартний бенчмарк.

Параметр	Значення
Диктор	Одна жінка-диктор (Linda Johnson)
Кількість записів	~13,100 аудіокліпів
Загальна тривалість	~24 години аудіо
Мова	Англійська
Формат аудіо	WAV, 22,050 Гц, моно, 16-bit
Джерело текстів	7 книг із публічного домену (Project Gutenberg)
Середня довжина кліпу	~1–10 секунд
Ліцензія	Public Domain

Датасет є стандартом де-факто для задач TTS з таких причин:

- Висока якість запису: студійні умови, чистий звук без шумів
- Однорідність: один диктор, стабільний темп і тембр мовлення
- Розмір: достатній для навчання нейромережових TTS-моделей
- Відкритий доступ: повністю у публічному домені, без ліцензійних обмежень
- Широке використання: дозволяє порівнювати результати з опублікованими роботами

Препроцесинг

Для підготовки даних до навчання виконувався наступний препроцесинг:

- Токенізація тексту: перетворення символів у послідовність індексів
- Отримання mel-спектрограм: трансформація аудіосигналу у частотно-часове представлення
- Нормалізація: текстові та аудіодані нормалізувалися для стабільного навчання
- Кодування аудіо у дискретні токени за допомогою vocoder/кодека для подачі на вхід LLM

Тренувальний пайплайн

Процес навчання

Модель навчалася як авторегресивний мовний моделювач над послідовностями аудіотокенів з умовою на текст. На вхід подавалися пари, модель вчилася передбачати наступний аудіотокен.

Інференс та стратегії семплінгу

Після навчання модель запускалася з різними підходами до семплінгу для оцінки якості та різноманітності генерації:

- Greedy decoding: вибір токена з максимальною ймовірністю на кожному кроці
- Temperature sampling: регулювання "творчості" генерації через параметр температури
- Top-k sampling: обмеження вибору топ-k найбільш імовірними токенами
- Top-p (nucleus) sampling: динамічне обмеження за накопиченою ймовірністю p

Тексти для інференсу були взяті з відкритих джерел або згенеровані за допомогою LLM.

Метрики

Для оцінки якості синтезованого мовлення використовувалися три метрики з роботи xTTS:

Метрика	Повна назва	Що вимірює
CER	Character Error Rate	Розбіжність між транскрибованим та оригінальним текстом .
UTMOS	Unified TTS MOS Score	Автоматична оцінка природності мовлення .
SECS	Speaker Encoder Cosine Similarity	Схожість голосу синтезованого та еталонного диктора. Ближче до 1 — краще.

Висновки

В рамках даної роботи була реалізована система синтезу мовлення на основі LLM-архітектури . Датасет LJ Speech забезпечив якісну та однорідну основу для навчання. Тренувальний пайплайн на PyTorch Lightning дозволив структуровано організувати процес оптимізації моделі. Різні стратегії семплінгу продемонстрували вплив гіперпараметрів на якість та різноманітність генерованого мовлення. Обчислені метрики CER, UTMOS та SECS дали змогу кількісно оцінити результати роботи системи.